



Enrique Abril Contreras

AI Engineer · Multi-Agent Systems · RAG · LLM Apps en Producción

LATAM · Remoto · kiketachira@gmail.com · +57 300 105 7454

linkedin.com/in/enrique-abril-contreras · github.com/kiketach · bio.fyllu.net

PERFIL

AI Engineer con experiencia comprobada llevando soluciones de IA **desde el diseño hasta producción real**: agentes conversacionales, sistemas multi-agente y arquitecturas RAG conectadas a procesos de negocio. **Ex-CTO** de una plataforma SaaS multi-tenant con IA, operando en producción con clientes reales. Construyo el stack completo de una app de IA: orquestación de agentes (Agency Swarm, OpenAI Agents SDK, Google ADK), capa LLM multi-proveedor (LiteLLM), tools/MCP, guardrails y salida estructurada, RAG sobre datos privados (pgvector), voz en tiempo real (Gemini Live / Vertex AI), backend FastAPI y despliegue en la nube (Cloud Run, Railway).

EXPERIENCIA PROFESIONAL

Full Stack AI Engineer & Technical Account Lead — MIMEIA

2025 – ACTUALIDAD

Soluciones de IA conversacional para múltiples clientes sobre Symphonai, la plataforma interna (DDD) para apps de agentes WhatsApp-first, con contribución al core.

- Agentes conversacionales y CRMs sobre WhatsApp para clientes de varios verticales (pettech, consultoría comercial, retail, clínica de estética/salud) como *thin-consumers* de la plataforma.
- **Agente por niveles de suscripción** (pettech): instrucciones, tools y guardrails compuestos en runtime según el tier del usuario; guardrails de entrada/salida con clasificador ligero (~100 ms) para bloquear consejos médicos; UX multimodal (texto, voz, imagen, PDF).
- **CRM AI-native** (consultoría comercial): diseño **event-sourced** (ledger inmutable de eventos; etapas del pipeline derivadas por reglas, no almacenadas) con orquestación multi-agente y agendamiento de reuniones.
- **Vertical de reservas** (appointment ERP *capacity-aware*): slots derivados on-demand y cacheados en Redis con Postgres como fuente de verdad; agente que opera solo a través de tools que envuelven servicios de dominio, garantizando las invariantes de capacidad.
- **Core de plataforma**: orquestación IA multi-proveedor (LiteLLM + OpenAI Responses API) con contabilización normalizada de tokens/costo (OpenAI, Anthropic, Google, ElevenLabs); backbone event-driven sobre **Redis Streams**; decisiones documentadas en ADRs.
- **Routing LLM resiliente**: Gemini sobre Vertex AI (service account) con fallback automático a otro proveedor ante errores o límites de tasa.

CTO & Lead AI Engineer — RentOSO SpA

2025 – 2026

Plataforma CRM + IA para el sector inmobiliario, bajo modelo SaaS multi-tenant. Chile · Remoto.

- Lideré la arquitectura y el desarrollo de la plataforma, además del equipo de desarrollo.
- Agentes de IA en producción con **Google ADK + Vertex AI Agent Engine + Gemini**, con arquitectura **multi-tenant sin re-despliegue** (alta de cliente = configuración, no deploy).
- Multi-tenant sobre Supabase + PostgreSQL con **Row-Level Security**; separación de dominios: FastAPI (IA e integraciones) y NestJS (core transaccional).
- Workflows conversacionales con validación documental, scoring de leads y automatización de captación por WhatsApp.
- Integraciones: WhatsApp Business API (Meta Tech Provider), Mercado Libre Inmuebles, Twilio (voz), Floid (scoring financiero), Cal.com.
- **Impacto: +11 agencias activas en producción**; alianzas negociadas con portales republicadores y con Mercado Libre Inmuebles para distribuir los agentes de IA.

AI Engineer · Intelligent Document Systems — Audisoft

2024 – 2025

IA para automatización documental y auditoría interna, clientes enterprise (Ecopetrol, Afinia, Banamex). Remoto.

- Asistentes conversacionales con **recuperación semántica (RAG)** sobre documentos no estructurados (PDF, correos, imágenes, Office).
- Pipeline **ETL** desde SQL Server hacia vector stores para consultas semánticas; sistemas híbridos SQL + NoSQL para retrieval empresarial.
- Integración de OpenAI, Azure Document Intelligence y MongoDB Atlas; arquitectura desacoplada (procesamiento, indexación, consulta semántica, generación).

PROYECTO PROPIO

KikeMind — Plataforma de IA para el crecimiento de developers

EN PRODUCCIÓN

Diseño, desarrollo y despliegue end-to-end: producto + arquitectura + código. [kikemind-9420c.web.app](#)

- **Mentor técnico conversacional** (texto y voz) sobre system design, cloud/GCP, DDD, agentes/LLMs, testing y entrevistas; suite de inglés (escribir, hablar, escuchar, leer).
- **Voz en tiempo real con Gemini Live** (native audio) sobre Vertex AI, vía WebSocket directo a Cloud Run con ticket de un solo uso.
- Clean Architecture / SOLID con IA desacoplada por puerto-adapter; **FastAPI** · **SQLModel** · **Supabase (JWT)** · **Alembic** · **React 19**; desplegado en Firebase Hosting + Cloud Run.

CommerceEngine / Fyllu — CRM + agente IA + POS para comercio conversacional por WhatsApp

PILOTO EN PRODUCCIÓN

Proyecto propio para PYMES LATAM · cliente piloto Le Boutique · Cloud Run · [fyllu.net](#)

DOCENCIA

Relator — Universidad de Santiago de Chile (USACH), Facultad Tecnológica

AGO 2026

Séptima Escuela de Temporada FACTEC · Modalidad virtual síncrona.

Diseño e impartición del curso **“Construye tu primer agente de IA: de la idea a un asistente funcional”** — 12 horas cronológicas, 51 participantes, en su mayoría profesionales sin experiencia previa en programación. De cero a un agente funcional: **function calling** con herramientas propias, **MCP (Model Context Protocol)** conectando servidores externos, preguntas sobre documentos propios (PDF) e interfaz web con voz.

51

participantes

100%

valoró el dominio del curso

100%

aprendió algo de valor real

84%

cumplió totalmente sus expectativas

HABILIDADES TÉCNICAS

IA / Agentes: Sistemas multi-agente (MAS), Agency Swarm, OpenAI Agents SDK, Google ADK, PydanticAI, LiteLLM, MCP (Model Context Protocol), RAG, embeddings, vector databases, function/tool calling, structured outputs, guardrails, prompt engineering, evaluación

Modelos & voz: OpenAI (GPT), Anthropic (Claude), Google Gemini, Gemini Live (Vertex AI), ElevenLabs, modelos open-source; multimodal (texto/imagen/voz)

Backend: Python, FastAPI, asyncio, Pydantic, SQLModel, TypeScript, NestJS, Next.js

Arquitectura: DDD, Clean Architecture / puertos-adapters, multi-tenant, event-driven (Redis Streams), SSE/WebSockets, plataforma-contrato (thin consumers)

Datos / Vector: PostgreSQL, Supabase, pgvector, Row-Level Security, MongoDB Atlas, SQL Server, Redis

Cloud / DevOps: Google Cloud Platform (Cloud Run, Vertex AI, Secret Manager), Railway, Docker, CI/CD, Firebase, Azure

Dev asistido por IA: Claude Code, Codex, Devin (SWE), DeepSeek Harness — flujos agénticos, revisión automatizada de cambios

Integraciones: WhatsApp Business API (Wappa), Mercado Libre API, Twilio, Meta API/CAPI, Google Calendar, webhooks, OAuth

EDUCACIÓN

- ✓ **U. Nac. Experimental del Táchira** — Ingeniería Informática · 2010–2012
- ✓ **Generation Colombia** — Desarrollo Full Stack (Java) · 2023
- ✓ **BIT Bogotá** — Front-end / aplicaciones web · 2022–2023

CERTIFICACIONES E IDIOMAS

- ✓ **Microsoft Azure AI Fundamentals (AI-900)**
- ✓ **Microsoft Azure Data Fundamentals (DP-900)**
- ✓ Español (nativo) · Inglés (B2 — intermedio alto)